머신러닝 기말 프로젝트

실증적 문제에 대한 딥러닝 기반의 알고리즘 설계 및 검증

키보드 타건 및 마우스 소리 분석을 통한 활동 내용 분류

2021161045 류황민

INDEX

01 문제 정의
키보드·마우스 입력음 기반 활동 분류 문제 소개

02 데이터 수집 및 전처리
녹음, 세그먼트 생성, 멜 스펙트럼, 데이터 분할

03 모델 구조 설계
초기 모델 vs 개선 모델, 규제 기법

04 실험 과정 및 결과 분석
6단계 실험과 정확도 향상 흐름

05 최종 모델 성능 평가
90% 정확도 및 모델 안정성 평가

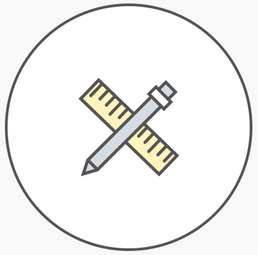
06 한계점 및 향후 개선 방향
데이터 문제, 배경소음 관련 한계, 느낀 점과 확장 의지

01 문제 정의



구분하기 어려운 사용자 활동

문서 작성, 웹서핑, 게임, 채팅 활동은
사람이 듣기에도 구별이 쉽지 않고 입력 패턴이 유사해
단순 음량·주기 등 기본적 특징만으로는 분류가 어렵다.



집중 흐트러짐 문제

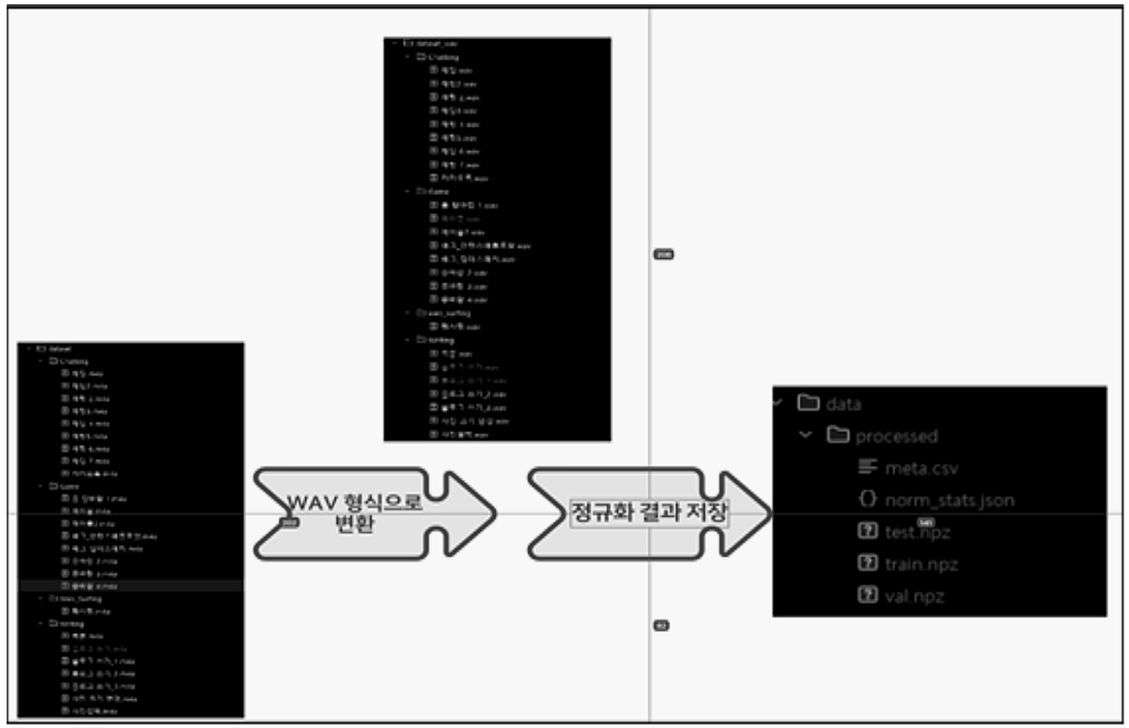
사용자는 특정 작업 중 의도치 않게 다른 활동
으로 전환되는 일이 잦으며
이를 자동으로 감지할 수 있다면 집중 유지 및
생산성 향상에 도움이 된다



필요성

키보드·마우스 입력은 모든 활동에서 발생하는 공통
신호이므로 이를 분석하여 사용자 활동을 자동 분류
하는 모델이 있다면 추후 경고 시스템이나 작업 모드
전환 등에 활용 가능하다.

02 데이터 수집 및 전처리



데이터 준비 과정 요약

이번 프로젝트의 데이터는 다양한 환경에서 직접 녹음한 키보드·마우스 소리로 구성되었다. 녹음된 원본 음성은 먼저 WAV 형식으로 통일하고, 16kHz·모노로 변환하여 장치별 차이를 최소화하였다. 이후 모든 음성은 10초 단위 세그먼트로 분할되었으며, 클래스별 데이터 양을 고려해 hop 크기를 다르게 설정하여 데이터 균형을 맞췄다.

각 세그먼트는 모델 입력을 위해 로그 멜 스펙트럼으로 변환되었고, 마지막으로 정규화 및 GroupShuffleSplit을 통한 데이터 누수 방지 절차를 거쳐 훈련·검증·테스트 세트가 구축되었다.

02 데이터 수집 및 전처리

데이터

01 원본 오디오 정리 및 WAV 변환

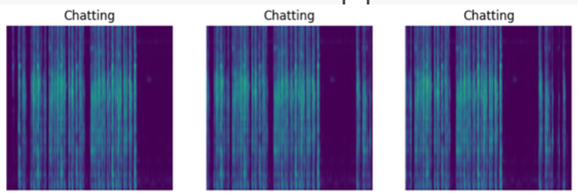
모든 녹음 파일을 m4a에서 WAV로 변환하고 샘플레이트 16kHz, 모노 채널로 통일하여 녹음 환경 차이로 발생하는 신호 불균일성을 최소화 하였다.

02 세그먼트 분할 및 hop 조정

각 파일을 10초 단위로 분할하고 클래스별 데이터 편차를 줄이기 위해 Chatting / Web Surfing은 짧은 hop, Game / Writing은 긴 hop으로 조정하여 자연스러운 데이터 균형을 확보하였다.

03 Log-Mel Spectrogram 변환

분할된 오디오를 64 Mel band 기반의 로그 멜 스펙트로그램으로 변환해 CNN이 학습 가능한 2차원 특징 형태로 구성하였다.



04 데이터 누수 방지 분리 및 정규화

GroupShuffleSplit을 사용해 같은 원본에서 나온 세그먼트가 train/val/test에 섞이지 않게 분리하였다. 또한 훈련 데이터의 평균과 표준편차로 전체 데이터를 정규화하고 train.npz, val.npz, test.npz로 저장하였다.

03 모델 구조 설계

초기 모델	개선 모델
채널 수가 적어 학습 용량 제한됨	채널 확장으로 더 풍부한 특징 학습 가능
드롭아웃 없음 → 과적합 쉽게 발생함	드롭아웃과 정규화 적용으로 과적합 완화
시간·주파수 특징 추출이 약함	시간축 압축(pooling) 강화로 이벤트 특징 선명화
검증 정확도와 손실 변화가 불안정함	전체 정확도 향상(약 55% → 약 85~ 약 90%)

04 실험 과정 및 결과 분석



초기 모델 구조 실험

기본 CNN 구조를 적용해 초기 성능 파악
클래스 불균형 + 단순 구조로 인해 과적합 발생 검증 정확도 급락, 손실 증가 → 구조 개선 필요성 확인
성능 59% 수준

Hop 크기 변경 실험 (1초 / 3초)

데이터 중복 생성 문제를 줄이기 위해 hop 조정
전처리 방식만 변경한 실험
성능 63% 수준으로 소폭 향상
그래도 검증곡선이 불안정하여 구조 개선 필요성 재확인

모델 구조 전면 개선

채널 확장, Dropout 추가
Flatten 대신 Global Average Pooling 기반 구조 실험
학습 안정성 증가, 과적합 감소
테스트 정확도 약 81% 달성

Hop 조합 실험

hop을 다시 세분화하여 샘플 다양성 증가 시도
모델 구조는 동일하게 유지
2번의 추가 실험 후 성능 약 88%까지 향상
다만 3차 실험 대비 드라마틱한 개선은 나타나지 않음

TF 버전 변경 및 최적화 조정

TensorFlow 2.x 환경에서 실험
성능은 약 90% 전후이지만,
hop 조정/버전 변경만으로는 구조적 개선 이상 성능 확보가 어려다 판단
실험 마무리

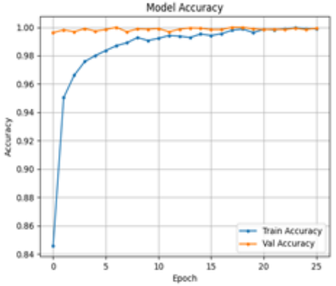
04 실험간 그래프 개선

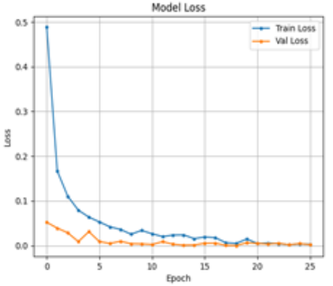

Training and Validation Accuracy
Training Accuracy
Validation Accuracy

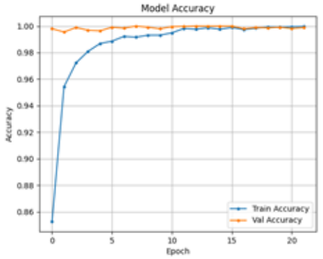

Training and Validation Loss
Training Loss
Validation Loss

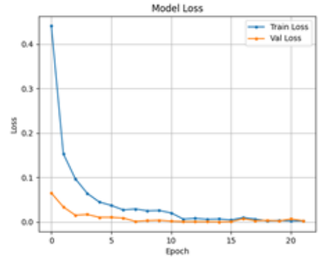

Training and Validation Accuracy
Training Accuracy
Validation Accuracy

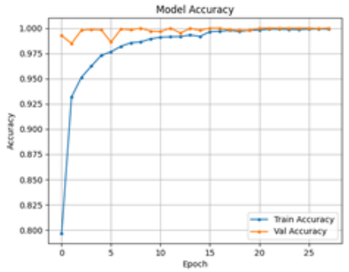

Training and Validation Loss

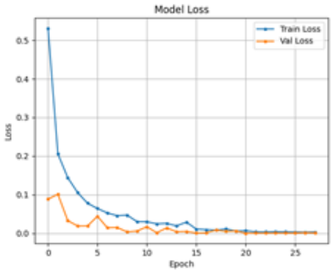

Model Accuracy
Accuracy
Epoch
Train Accuracy
Val Accuracy

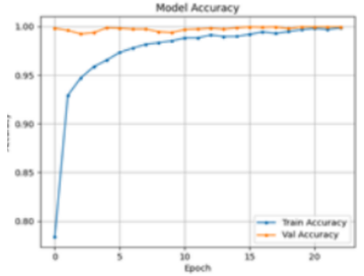

Model Loss
Loss
Epoch
Train Loss
Val Loss

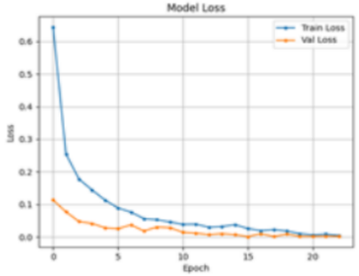

Model Accuracy
Accuracy
Epoch
Train Accuracy
Val Accuracy


Model Loss
Loss
Epoch
Train Loss
Val Loss


Model Accuracy
Accuracy
Epoch
Train Accuracy
Val Accuracy


Model Loss
Loss
Epoch
Train Loss
Val Loss


Model Accuracy
Epoch
Train Accuracy
Val Accuracy


Model Loss
Loss
Epoch
Train Loss
Val Loss

05

최종 모델 성능 평가



01	초기 모델 대비 성능 향상 폭 확인
02	구조 개선 모델의 안정적 수렴
03	Hop 조정 실험의 영향 분석
04	TensorFlow 버전별 성능 비교 결과
05	최종 모델의 실제 테스트 성능: 90% 수준의 분류 성능

06

한계점 및 향후 개선 방향

01

데이터 수집의 구조적 한계

실제 사용 환경을 충분히 반영하기에는 전체 데이터량이 부족했으며, 클래스 간 수집량 불균형으로 인해 모델이 특정 패턴에 치우칠 가능성이 존재함.
또한 대부분의 데이터를 조용한 환경에서 녹음해 배경 소음에 대한 일반화가 제한적이었음.

02

세그먼트 분할 방식의 한계와 개선 방향

hop 크기 실험(0.5초, 1초, 1.5초, 3초)을 통해 성능 차이를 비교했지만, 극적인 성능 개선은 확인되지 못함.

데이터 확장

03

특징 추출 및 모델 구조의 확장성 부족

Log-Mel Spectrogram 기반 CNN 모델은 단순하고 효과적이나 추가적인 모델 탐색은 부족함

04

실제 사용 환경을 고려한 일반화 능력 강화 필요

현재 모델은 녹음 환경 변화에 약할 가능성이 큼.
향후에는 기회가 된다면 배경 소음 분류·제거 모델과 결합하거나,다양한 소음 조건에서 훈련하여 실제 사용 환경에서도 안정적인 성능을 확보하도록 개선할 수 있음.


Q&A